

# OCVX Case Study

Exam II - Juillet 2019

Daoud Karim, Misk Nicolas, Andersen Simon

# Les problèmes étudiés

## Descente de gradient

- Comparaison différents pas
- Comparaison norme L1-L2

## Méthodes d'optimisation

- Learning rate scheduling
- Nesterov
- Adam

## Méthode de Newton

- Descente de gradient avec Newton
- Quasi-newton

# Descente de gradient

- Permet de minimiser une fonction
- Algorithme très utilisé dans le machine learning
- De nombreuses variantes et optimisations possible


Légende:

Nombre d'itérations

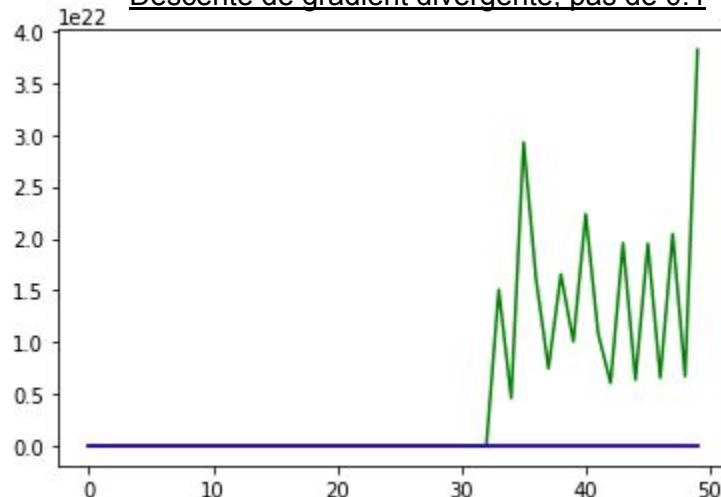
Valeur objective trouvée

Nombre de conditionnement


Descente de gradient, pas de 0.1



Descente de gradient divergente, pas de 0.1




# Descente de gradient : comparatif




# Comparaison norme L1 - L2

- Le nombre d'itération converge vers la même valeur quand le nombre de conditionnement augmente.
- En norme L1 les itérations suivent la direction du gradient.
- En norme L2 les itérations suivent les directions de l'axe orthogonal.




Nombre d'itération en fonction du conditionnement



Visualisation des itérations


# Etude du point de départ de la descente



Nombre d'itérations en fonction du point de départ  
en norme L1

- Le nombre d'itérations ne dépend pas de la distance par rapport au point optimal.
- Les coordonnées négatives en Y semblent donner de meilleurs résultats.
- Les pires résultats sont pour les coordonnées en X négatifs et Y positifs.

# Etude du point de départ de la descente




- Dépend fortement de la distance en X.

Nombre d'itérations en fonction du point de départ  
en norme L2


# Méthodes d'optimisations



# Learning rate scheduling



Learning rate scheduling, pas de 0.3



Descente classique, pas de 0.3

- Variation du step en fonction du nombre d'itérations.
- Implémentation d'un learning rate décroissant, méthode exponentielle

$$S_n = S_0 \cdot e^{-k \cdot t}$$


Avec  $S_i$  le step à l'itération  $i$ , et  $k$  un hyperparamètre introduit.

- On obtient une convergence pour les nombres de conditionnement élevés avec un step de 0.3

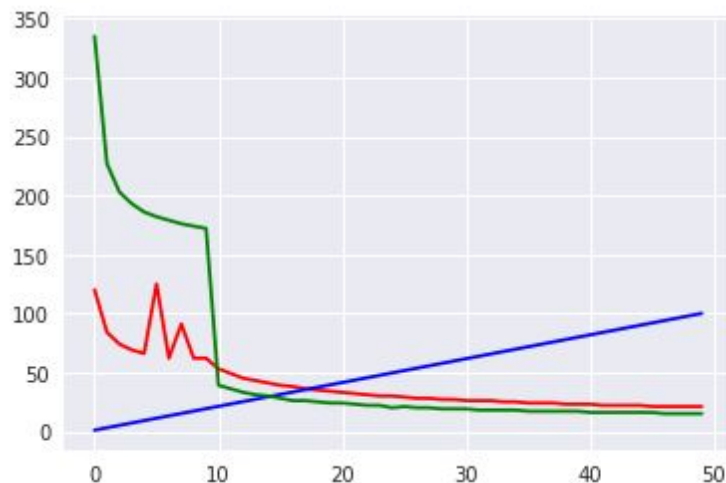
# Nesterov

- Accélération de la descente via une nouvelle méthode de calcul des itérations

Pas de 0.1, nombre de conditionnement de 0 à 10



Pas de 0.1, nombre de conditionnement de 0 à 100



Légende:

Nombre d'itérations (Nesterov)

Nombre d'itérations (Descente classique)

Nombre de conditionnement

# Adam optimization

Légende:


Nombre d'itérations (Adam)

Nombre d'itérations (Descente classique)


Nombre de conditionnement

- Adaptive Moment Estimation
- Moyennes mobiles du moment d'ordre 1 et 2

Hyperparamètres par défaut




Hyperparamètres adaptés



# Adam Optimization: direction de la descente


- Converge très rapidement sur les problèmes convexes.
- 20 itérations dans notre exemple



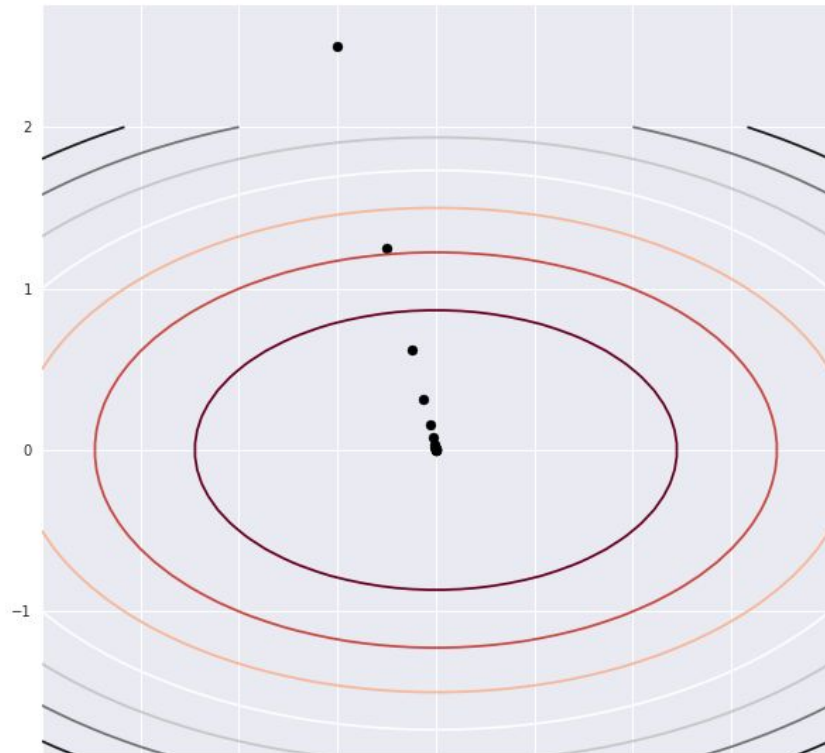
# Méthode de Newton

# Descente de gradient avec Newton

- La méthode de Newton permet d'obtenir les zéros d'une fonction
- Dans le cas d'une descente de gradient, un minimum  $x$  est disponible lorsque  $\text{grad}(f(x)) = 0$



iterations: 14



# Quasi Newton

- Dérive de la méthode de Newton
- Utilise une approximation du de la Jacobienne
- Permet d'optimiser les calculs lorsque les matrices deviennent importantes

# Conclusion

- Il existe différentes méthodes pour optimiser une descente de gradient
- Selon le besoin, il convient d'utiliser une méthode plutôt qu'une autre
- Il est important de chercher les paramètres les mieux adaptés à notre problème (learning rate, hyperparamètres, ...)





Des questions?